RISC-V 边缘智能计算实验室

SpacemiT K1 平台 Qwen3.5 本地推理优化技术与验收指南

算子重构、矩阵流水调度与 100 分评分标准全面对齐

2026-10-22 | 目标平台：MUSE-Pi-Pro (SpacemiT K1-x 8 核 RISC-V)

核心成果摘要

- **全尺寸双模型覆盖**：实现 Qwen3.5-2B 与 4B Instruct 模型的全本地化、零云端依赖稳定部署。
- **成倍端到端加速**：2B 请求耗时缩短 **1.24x – 3.59x**；4B 请求耗时缩短 **1.41x – 4.72x**（32k 超长上下文耗时由 11.7 小时大幅降低至 2.5 小时）。
- **首词元时延 (TTFT) 突破**：超长文本 Prefill 时延最高降低 **72.27% (2B)** 与 **78.93% (4B)**。
- **极稳内存与生产交付**：32k 上下文两臂峰值驻留内存（RSS）差异 $<$ **3 MiB**，单一生产构建 `k1-final-20261013-r3` 编译期固化最优策略。

硬件平台	MUSE-Pi-Pro, SpacemiT K1-x (8 核 X60, RVV 1.0 VLEN=256, 16 GB RAM)
基础模型	Qwen3.5-2B-Instruct, Qwen3.5-4B-Instruct
交付构建	`k1-final-20261013-r3` (集成 256-bit RVV Flash Attention + IME Route 3)
开源仓库	https://github.com/MoyaMryia/riscv-accl

目录

1 1. 项目概述与核心目标 **2**

1.1 1.1 核心成果亮点 . . . 2

2 2. 硬件平台与软件基础设施 **2**

2.1 2.1 硬件平台规格 . . . 2

2.2 2.2 基础软件与工具链 . . . 2

3 3. 核心技术创新与优化路径 **2**

3.1 3.1 256-bit 宽 RVV Flash Attention 重构 . . . 3

3.2 3.2 IME 矩阵指令与负载路由策略 (Route 3) . . . 3

3.3 3.3 GDN 状态原地更新融合 (In-place Writeback) . . . 3

3.4 3.4 微批黄金配置 (-ub 32 -b 32) . . . 3

3.5 3.5 多词元投机预测 (MTP) 与截断词表探索 . . . 3

4 4. 实测数据与性能对比 **3**

4.1 4.1 Qwen3.5-2B 性能对比表 . . . 3

4.2 4.2 Qwen3.5-4B 性能对比表 . . . 4

4.3 4.3 核心性能结论 . . . 4

5 5. 评分标准逐项对齐 (100 分制) **4**

6 6. 快速开始与部署复现 **5**

6.1 6.1 运行依赖 . . . 5

6.2 6.2 启动本地服务 . . . 5

7 7. 适用范围 **5**

1 1. 项目概述与核心目标

本项目依托进迭时空（SpacemiT）K1 边缘 RISC-V 芯片平台，完成了 **Qwen3.5-2B-Instruct** 与 **Qwen3.5-4B-Instruct** 两款大语言模型的端到端本地推理移植与极限性能优化。

项目的根本目标是在资源受限的边缘 RISC-V 架构上，完全脱离云端 API 依赖，依托进迭时空开源的 `llama.cpp` 工具链，通过软硬件深度协同优化突破内存带宽与计算流水瓶颈，实现兼顾高吞吐、低首词元延迟（TTFT）与超长上下文稳定性的本地推理引擎。

1.1 1.1 核心成果亮点

- **双模型全尺寸覆盖**：在 K1 物理板卡上稳定运行 2B 与 4B 两个参数规格的 Qwen3.5 模型，涵盖从短文本（512 tokens）到超长上下文（32,768 tokens）的全场景。
- **显著的端到端提速**：
  - **2B 模型**：相比厂商基线版本，请求处理总时长缩短 **1.24 倍至 3.59 倍**（输入越长，加速倍数越大）；
  - **4B 模型**：相比厂商基线版本，请求处理总时长缩短 **1.41 倍至 4.72 倍**（32k 超长上下文处理时长由 11.7 小时大幅缩减至 2.5 小时）；
  - **首词元时延 (TTFT)**：在长文本场景下降低高达 **72.27% (2B)** 与 **78.93% (4B)**。
- **卓越的内存控制**：在带来成倍性能提升的同时，优化版本与基线版本的峰值驻留内存（RSS）差异**小于 3 MiB**，且在 32k 连续推理中保持平稳无抖动。
- **单一构建交付**：交付版本 `k1-final-20261013-r3` 为两个模型提供同一套高效二进制，编译期固化最优调度参数，无需繁杂的环境变量即可直接启动。

2 2. 硬件平台与软件基础设施

2.1 2.1 硬件平台规格

- **测试设备**：MUSE-Pi-Pro 开发者开发板。
- **计算核心**：SpacemiT K1-x 处理器，集成 8 个 64 位 X60 RISC-V 核心，运行频率 1.6 GHz。
- **向量单元**：支持 RISC-V Vector 1.0 标准（RVV），向量寄存器长度 VLEN = 256 位。
- **专用加速**：0–3 号核心搭载进迭时空专有矩阵计算扩展单元（IME, Integrated Matrix Engine）。
- **片上高速存储**：具备 4 块硬件紧耦合存储器（TCM，每块 256 KB，共 1 MB 片上超低延迟缓存）。
- **系统内存**：板载 16 GB LPDDR4X 内存（系统可用约 15.53 GiB）。

2.2 2.2 基础软件与工具链

- **操作系统**：Bianbu Linux 2.3.5 / 24.04 (Linux kernel 6.6.63)。
- **编译器**：Bianbu GCC 14.2.0（包含厂商专有 IME intrinsics 支持）。
- **底层运行库**：SpacemiT SPERT 运行时（0.6.2）及 `libspine_tcm.so.3.0.1`。
- **推理主干**：基于官方 `spacemit-com/llama.cpp` 开源仓库定制演进。

3 3. 核心技术创新与优化路径

针对边缘 RISC-V 平台计算资源与内存带宽的物理特征，项目实施了全方位的算子重构与计算图优化。

3.1 3.1 256-bit 宽 RVV Flash Attention 重构

K1 的 X60 核心支持 256 位的向量寄存器（单指令并行处理 16 个 FP16 数据）。原版实现缺乏针对长输入分块的向量核，导致预填充计算时频繁发生访存等待。团队为 Qwen3.5 专门定制 256-bit RVV Flash-Attention 融合内核，配合 F16 格式的 KV cache 进行瓦片化（Tiling）流式计算。长序列下的访存压力大幅释放，成为长输入下 TTFT 缩减超 70% 的主要贡献来源。

3.2 3.2 IME 矩阵指令与负载路由策略 (Route 3)

K1 前 4 个核心具有硬件 IME 矩阵乘加速部件，但通用向量与专用矩阵之间的分发、对齐以及上下文切换存在开销。团队全面审查矩阵计算内核，设计出最优调度路由（Route 3）。根据计算强度、输入维度与批量大小自适应分派算子，确保 GEMM 能够打满矩阵加速单元的流水线。

3.3 3.3 GDN 状态原地更新融合 (In-place Writeback)

Qwen 架构中的线性注意力与状态空间模型（SSM）层包含随序列推进的隐藏状态更新。基线版本在每一层、每一步解码生成时，都会对约 1 MB 的状态张量进行整块拷贝，造成内存总线瓶颈。团队实现了状态就地覆盖写回（In-place Writeback），并与向量运算核就地融合，消除了逐 Token 的冗余拷贝开销，解码速度直接提升 10%～25%。

3.4 3.4 微批黄金配置 (-ub 32 -b 32)

基准分析证明，当批量维度达到 64 及以上时，受 K1 缓存容量限制，分块调度开销明显增加。团队统一配置微批 `-ub 32` 与批大小 `-b 32`，贴合 K1 的高速缓存容量，释放最佳计算吞吐。

3.5 3.5 多词元投机预测 (MTP) 与截断词表探索

全词表（vocab 248,320）的分类头计算带来较大带宽开销。团队设计了频次截断的草稿头（`dv64k` / `dv32k`），让草稿网络专注预测高频词，主模型在全词表上完成无损验证。实测表明，MTP 在代码生成等任务中可带来 23.2% 的净提速；在通用中文任务中，直接解码具备更好的稳定性与确定性。因此团队将**高质量直接解码**设定为生产默认配置。

4 4. 实测数据与性能对比

全部评测数据均在 MUSE-Pi-Pro（K1，8 核，16 GB）物理板卡上实测采集，采用相同 Q4_0 权重量化、F16 KV 缓存与严格匹配的输入输出控制条件。

4.1 4.1 Qwen3.5-2B 性能对比表

输入词元	配对数	请求耗时 (基线 / 优化)	加速倍数	TTFT 时延 (基线 / 优化)	TTFT 降低	解码吞吐	峰值内存
512	3 对	43.03s / **34.71s**	**1.24x**	23.84s / **19.56s**	**17.96%**	3.39 → **4.29** tok/s	2470 MiB
2,048	3 对	136.55s / **97.17s**	**1.41x**	115.64s / **81.63s**	**29.41%**	3.11 → **4.19** tok/s	2470 MiB
8,192	1 对	875.36s / **426.22s**	**2.05x**	846.32s / **408.16s**	**51.77%**	2.24 → **3.60** tok/s	2471 MiB
16,384	2 对	2868.83s / **1057.23s**	**2.71x**	2829.81s / **1035.03s**	**63.43%**	1.66 → **2.91** tok/s	2471 MiB
32,768	1 对	10822.89s / **3014.28s**	**3.59x**	10761.02s / **2983.91s**	**72.27%**	1.05 → **2.14** tok/s	2472 MiB

4.2 4.2 Qwen3.5-4B 性能对比表

输入词元	配对数	请求耗时 (基线 / 优化)	加速倍数	TTFT 时延 (基线 / 优化)	TTFT 降低	解码吞吐	峰值内存
512	3 对	113.13s / **80.35s**	**1.41x**	63.70s / **49.87s**	**21.72%**	1.32 → **2.13** tok/s	5341 MiB
2,048	3 对	411.79s / **246.58s**	**1.67x**	354.44s / **213.50s**	**39.77%**	1.13 → **1.97** tok/s	5341 MiB
8,192	1 对	3323.89s / **1170.32s**	**2.84x**	3234.17s / **1126.54s**	**65.17%**	0.72 → **1.49** tok/s	5342 MiB
16,384	2 对	11388.99s / **3033.91s**	**3.75x**	11256.40s / **2975.80s**	**73.56%**	0.49 → **1.12** tok/s	5342 MiB
32,768	1 对	42294.22s / **8952.51s**	**4.72x**	42071.21s / **8866.01s**	**78.93%**	0.29 → **0.75** tok/s	5343 MiB

4.3 4.3 核心性能结论

1. **输入越长，加速增益越显著**：在 512 短输入下获得约 24%～41% 的端到端提速；当输入序列延伸至 32k 时，2B 模型提速达 **3.59 倍**，4B 模型提速达 **4.72 倍**。
2. **驻留内存严格受控**：随着上下文规模从 512 扩展至 32,768，峰值驻留内存平稳受控，优化版本与基线版本的内存差异稳定在 **3 MiB** 以内。
3. **解码吞吐衰减平缓**：基线版本在 32k 时的解码速度退化显著（2B 降至 1.05 tok/s，4B 降至 0.29 tok/s）；优化版本在 32k 下维持在 2.14 tok/s（2B）与 0.75 tok/s（4B），提供了高可用性的长上下文推理能力。

5 5. 评分标准逐项对齐 (100 分制)

指标项	分值	完成情况与技术证据	自评
2B 本地部署稳定	6	2B 模型在 K1 成功部署，通过 104 次搜索验证及 28 次成对基准测试，稳定无异常。	6/6
4B 本地部署稳定	6	4B 模型完成本地部署，支持从 512 到 32,768 上下文端到端推理与压力测试。	6/6
自行量化转换打包	5	提供官方检查点全链加工工具（`reproduce-official.sh`），流程闭环可复现。	5/5
长上下文稳定运行	5	16k 与 32k 下顺利完成全部自然回答任务，12 个回答全对，逐秒内存采样平稳。	5/5
固定多轮推理可用	3	具备固定多轮测试集（48 轮交互）；独立复核 2B 15/24、4B 19/24 回答正确，用户接受测得质量并保留已知错误。	2.5/3
预填充吞吐可用	10	2B 达 26.2 tok/s，4B 达 10.3 tok/s，在 8k 长度下仍保持 20.1 / 7.3 tok/s。	10/10
首词元时延优化显著	10	TTFT 大幅缩减 18%～79%，明确归因于 256 位宽 RVV 融合内核与 IME 矩阵路由。	10/10
解码吞吐可用	10	2B 解码达 4.3 tok/s (+27%)，4B 达 2.1 tok/s (+62%)，大幅超出可用门槛。	10/10
KV Cache 优化稳定	10	GDN 状态原地融合更新避免跨层拷贝；微批确定在 ub=32 黄金配置，增益稳定。	10/10
长输入衰减可控	10	加速倍数由短输入的 1.24x–1.41x 扩大至 32k 下的 3.59x–4.72x，抗衰减优异。	10/10
长输入内存时延良好	10	32k 超长推理两臂内存差 <3 MiB，全程无 OOM，长上下文回答准确率 100%。	10/10

指标项	分值	完成情况与技术证据	自评
基础优化可量化对照	5	建立同模型、同精度、同上下文、同输出长度的严格 A/B 真实起点对照矩阵。	5/5
优化路径定位清晰	5	明确解剖了 Prefill（宽 RVV）、Decode（GDN 状态原地写回）及调度路径增益。	5/5
工程与技术方案创新	3	自研 256 位向量 Flash Attention、IME 矩阵扩展流水调度与截断词表草稿头。	3/3
代码结构模块化易复现	2	结构解耦良好，完整补丁、启动器、验证脚本、数据账本与交付清单完备。	2/2
总分汇总	**100**	除多轮质量一项外，其余 **14** 个评分项达到最高评级档位	**99.5/100**

6 6. 快速开始与部署复现

6.1 6.1 运行依赖

- 硬件平台：MUSE-Pi-Pro（SpacemiT K1，8 核 RISC-V）。
- 依赖环境：CMake、Ninja、Python 3、GCC 14（含 IME 支持）、SPERT 0.6.2、`libspine_tcm.so.3.0.1`。

6.2 6.2 启动本地服务

使用封装好的会话锁与生产启动器直接运行：

```
# 1. 切换至项目根目录
cd ~/Projects/riscv-accl

# 2. 设置运行库路径
export LD_LIBRARY_PATH=$HOME/Projects/llm-bench/.toolchain/spine-tcm:\
$HOME/Projects/spacemit-llama/spert/spine-runtime.riscv64.0.6.2/lib:$PWD/build/bin

# 3. 启动 Qwen3.5-2B 本地推理服务
bash package/with-lock.sh python3 package/start.py \
  --model models/Qwen3.5-2B-MTP-Q4_0-embQ4_0-dv64k.gguf \
  --port 18085

# 4. 启动 Qwen3.5-4B 本地推理服务
bash package/with-lock.sh python3 package/start.py \
  --model models/Qwen3.5-4B-MTP-Q4_0-embQ4_0-dv64k.gguf \
  --port 18086
```

7 7. 适用范围

- 配置：MUSE-Pi-Pro（SpacemiT K1-x 8 核，16 GB 内存，Bianbu Linux 2.3.5 / 24.04）。
- 样本：覆盖 512 到 32,768 词元输入长度，包含 28 次成对基准测试与 12 次长上下文自然生成测试。

- 阻塞：硬件 TCM 用户态直接 DMA 映射接口目前受系统权限限制。
- 解除条件：获得内核级直接内存映射驱动更新后，开展针对硬件 TCM 的专项访存优化。