RISC-V 本地推理

面向进迭时空 K1 的 Qwen3.5 本地推理优化

基础设施优化与性能评估

证据截止：2026-10-16（Asia/Singapore）

平台 MUSE-Pi-Pro，K1 ／ X60，标称 16 GB 内存
模型 Qwen3.5 2B 和 4B
实现 SpaceMiT llama.cpp 分支
内容 中文技术报告

本报告比较最终默认构建与厂商起点。证据附录见英文报告。

github.com/MoyaMryia/riscv-accl

目录

摘要 2

1. 要求与状态 2

2. 平台与软件身份 3

3. 起点与兼容修改 3

4. 均衡默认配置的选择 4

5. 匹配性能结果 4

6. 正确性与失败记录 6

7. 部署与证据包 6

8. 历史证据 7

适用范围 7

证据截止：2026-10-16，Asia/Singapore。

摘要

最终版完成一次请求的速度，2B 为起点的 1.24～3.59 倍，4B 为起点的 1.41～4.72 倍。起点为厂商 `5ad05d8` 加两项兼容修改。输入越长，收益越大。服务器内存基本不变，两臂之差小于 3 MiB。

模型	输入词元	配对数	请求时长，s	加速倍数	首词元时间减少	解码，词元/s
2B	512	3	43.031 ／ 34.714	1.24 倍	17.96%	3.387 ／ 4.292
2B	2048	3	136.554 ／ 97.169	1.41 倍	29.41%	3.108 ／ 4.186
2B	8192	1	875.359 ／ 426.221	2.05 倍	51.77%	2.239 ／ 3.600
2B	16384	2	2868.832 ／ 1057.226	2.71 倍	63.43%	1.659 ／ 2.914
2B	32768	1	10822.886 ／ 3014.282	3.59 倍	72.27%	1.051 ／ 2.141
4B	512	3	113.128 ／ 80.346	1.41 倍	21.72%	1.315 ／ 2.133
4B	2048	3	411.793 ／ 246.579	1.67 倍	39.77%	1.133 ／ 1.965
4B	8192	1	3323.894 ／ 1170.324	2.84 倍	65.17%	0.724 ／ 1.485
4B	16384	2	11388.985 ／ 3033.905	3.75 倍	73.56%	0.490 ／ 1.117
4B	32768	1	42294.220 ／ 8952.505	4.72 倍	78.93%	0.291 ／ 0.752

斜线前为起点均值，斜线后为最终版均值。加速倍数为起点请求时长除以最终版请求时长。两臂使用相同的 Q4_0 权重、F16 缓存、输入和 65 个输出词元。完整数据见第 5 节。

版本 `k1-final-20261013-r3` 是两个模型共用的一份构建。选定参数写在源码中，普通启动不需要性能参数或实验变量。该构建通过原生检查、状态检查、自然代码回答和迁移启动检查。默认配置是冻结搜索中的均衡选择。样本数和待验收项见文末 “适用范围”。

1. 要求与状态

Requirements.md 是唯一的现行验收依据。它要求两个指定基座模型、本地推理、厂商分支、匹配对照提升和可复现部署材料。它没有规定 8 GB 设备或 32k ／ 64k 上下文。完整要求对照见缺口报告。

状态	内容
已实现	一套完整源码、一份生产构建、固化默认值、依赖检查和统一启动器
已验证	两个现用 GGUF 在 K1 上本地运行，不调用云端 API
已验证	28 次普通默认性能请求、12 次容量扩展请求和 6 次完整自然代码回答
已验证	原生转储逐位一致、64 条短状态记录和两个模型的迁移启动
待验收	官方模型来源和两个最终权重的可复现转换
待验收	长上下文重复稳定性、长状态和固定多轮质量套件
本版未实现	GPU 加速、KV 压缩和分页分配的内存收益

本项目没有对外比赛提交记录。

2. 平台与软件身份

测试板为 MUSE-Pi-Pro，有 8 个 K1 ／ X60 CPU 核。标称内存为 16 GB，Linux 报告约 15.528 GiB。记录的 CPU 频率为 1.6 GHz。测试在 tmux 中以普通用户执行，并持有板端共用锁。本轮测试没有修改设备权限或系统设置。

项目	身份
最终版本	`k1-final-20261013-r3`
厂商源码	`a990751d55a4c54acf2bb77d44282c2093652359`
完整源码文件数	3271
最终补丁 SHA-256	`b03d193f618d8303ce563c4fcd4e03726a1f6f45 2dcc10ecedb1a7938550477b`
服务器 SHA-256	`f254f174919c0a97ef34366f116705f6d22574ca b4c2bfc39928c0d315b5bfbd`
配置记录 SHA-256	`aeef14e2356dc9e33b1fc6ab595545eb67af8189 4f2c7cbd282948628453bdb0`
编译器	GCC 14.2.0，含厂商 IME 支持
运行库	SPERT 0.6.2 和 `libspine_tcm.so.3.0.1`，文件散列见构建收据
构建	Release，IME1 开，OpenMP 关，Native 关，ZBA 开，repack 关，CPU 后端

两个模型文件均为 Q4_0 权重和 Q4_0 嵌入。文件名含 MTP，表示文件带有草稿张量；本版使用直接解码。交付包不含模型权重和厂商运行库。

模型	GGUF SHA-256
`Qwen3.5-2B-MTP-Q4_0-embQ4_0-dv64k.gguf`	`56f0ddd90dfa0e2456af6cb4718ece419678d21a 75d65e27353319b5e431a2fa`
`Qwen3.5-4B-MTP-Q4_0-embQ4_0-dv64k.gguf`	`0adf6cce5df53921606033c39a13fae2054543b7 8af0e7ff98860e86f078ac0f`

最终版 TCM 跟踪核对了两次短请求的设备访问。两个服务器都加载了固定库，但访问硬件 TCM 返回 `EACCES`。13 份进程映射中没有 `/dev/tcm`。`/dev/tcm_sync_mem` 不存在，共享屏障回退到堆内存。这两次请求只用于跟踪设备访问，没有产生新的性能或质量结果。

3. 起点与兼容修改

起点为 SpaceMiT 分支的 `5ad05d8796cb094ee23a3a0152874f8a2b3060f8`。原版 K1 构建纳入了一个 IME2 文件，构建失败。第一项兼容修改只删除这一个 CMake 源文件列表项。修改后的构建无法加载当前模型的缩减 MTP 草稿头。第二项兼容修改读取 `d2t`，并按存储宽度加载草稿头。两臂都没有启用草稿解码。

修改只涉及 CMake 列表和 `src/models/qwen35.cpp` 中的张量加载函数。主输出头、计算图代码和全部计算内核保持原版字节。兼容补丁 SHA-256 为 `2e8c40a4a056787380e37750bab005777580978d3d9a58d901e911dc12fe01d7`。两次失败和两项兼容修改的记录都保存在证据中。

两臂都使用 4 线程、批大小 32、上下文 12288、单槽和 F16 键值缓存。两臂使用相同的编译器和运行库。测

得的收益是从原始软件到最终软件的整体收益。历史权重量化的变化不计入收益。

4. 均衡默认配置的选择

冻结搜索使用一份已核验的 RC1 构建，共 104 次请求。4 次预检在原版和候选构建上检查两个模型。掩码阶段在两个模型、两种长度上测试 8 种组合，各两轮。参数阶段测试 2 ／ 4 线程和 16 ／ 32 ／ 64 ／ 128 批大小。4 次自然回答完成选型检查。参数阶段保留 4 线程和批大小 32，没有触发额外复验或回退。

均衡分数对两个模型、两种长度、首词元时间和解码耗时赋相同权重。首词元时间指客户端从发出请求到收到第一个输出词元的时间。与最低分相差 3% 以内的组合，按冻结规则视为无法区分。在该区间内，规则优先选择启用候选较少的组合。掩码 7 的观测分数最低，为 0.8904876472483813。掩码 3 的分数为 0.915536301962804，处于该区间内，因此规则选择掩码 3。选型分数相对同构建的 C0 对照计算，与第 5 节的真实起点对照分开。

编译默认值	取值
工作线程与批线程	4 ／ 4
批大小与微批大小	32 ／ 32
上下文与槽位	12288 ／ 1
缓存与注意力	F16 键值缓存，闪存注意力开
GPU 层数与解码	0，直接解码
公共路径	宽 RVV 注意力和 IME route 3 开
候选掩码	3：B1-r2 和 C1 开，C2-r2 关

启动器清除继承的实验变量。最终服务器只接收模型、别名、主机和端口参数。运行日志和服务器属性确认了实际默认值。

5. 匹配性能结果

性能请求使用固定的完整输入词元列表和 65 个固定输出词元。单词元偏置使两个版本的解码历史完全相同。这一合成负载只测性能，答案质量由单独的自然回答请求检查。

所有请求的提示缓存复用为 0。测试不清理操作系统文件缓存。每次请求前重新启动服务器，加载时间不计入请求计时。28 次请求全部完成，每次都生成 65 个词元。输入散列、输出词元、全文和计时都符合协议。

短输入每形状 3 对，两臂顺序交替。8192 输入每个模型 1 对，两个模型采用相反顺序。表中数值为每臂请求指标的算术均值，斜线前为起点，斜线后为最终版。时间减少和吞吐增加使用不同的计算公式。

模型	输入	配对数	首词元时间，s	服务端预填充，s	预填充，词元/s
2B	512	3	23.835 ／ 19.556	23.831 ／ 19.551	21.485 ／ 26.188
2B	2048	3	115.639 ／ 81.633	115.632 ／ 81.626	17.712 ／ 25.090
2B	8192	1	846.321 ／ 408.162	846.303 ／ 408.145	9.680 ／ 20.071
4B	512	3	63.697 ／ 49.865	63.692 ／ 49.860	8.039 ／ 10.269
4B	2048	3	354.441 ／ 213.497	354.434 ／ 213.490	5.778 ／ 9.593
4B	8192	1	3234.172 ／ 1126.535	3234.155 ／ 1126.518	2.533 ／ 7.272

模型	输入	解码，词元/s	吞吐变化	请求时长，s	采样峰值 RSS，MiB
2B	512	3.387 ／ 4.292	+26.69%	43.031 ／ 34.714	2471.97 ／ 2469.73
2B	2048	3.108 ／ 4.186	+34.68%	136.554 ／ 97.169	2472.29 ／ 2469.96
2B	8192	2.239 ／ 3.600	+60.82%	875.359 ／ 426.221	2473.30 ／ 2471.19
4B	512	1.315 ／ 2.133	+62.17%	113.128 ／ 80.346	5342.20 ／ 5340.58
4B	2048	1.133 ／ 1.965	+73.37%	411.793 ／ 246.579	5342.20 ／ 5340.88
4B	8192	0.724 ／ 1.485	+104.91%	3323.894 ／ 1170.324	5342.88 ／ 5342.11

模型	输入	首词元时间减少	预填充吞吐变化	解码耗时减少
2B	512	17.96%	+21.89%	21.04%
2B	2048	29.41%	+41.66%	25.72%
2B	8192	51.77%	+107.35%	37.82%
4B	512	21.72%	+27.74%	38.34%
4B	2048	39.77%	+66.02%	42.32%
4B	8192	65.17%	+187.09%	51.20%

RSS 指服务器进程的驻留内存。表中为每次请求采样峰值的均值，采样间隔 0.2 s。独立汇总保存了均值、中位数、最小值、最大值和每次请求的身份。按冻结门槛，所有形状的首词元时间和解码耗时都没有明确退化。门槛取 3% 与起点臂完整波动范围中的较大值。

5.1 最终版容量扩展

单独的冻结协议把容量扩展到 20480 或 36864，对应实际输入 16384 或 32768 词元。最终服务器除模型、别名、主机和端口外，只额外接收容量参数。优化默认值不变，普通默认上下文仍为 12288。两个模型的全部请求都完成，输出 65 个匹配词元，提示复用为 0。16384 输入每个模型 2 对，32768 输入每个模型 1 对。

模型	输入	配对数	首词元时间，s	预填充，s	预填充，词元/s
2B	16384	2	2829.646 ／ 1034.907	2829.614 ／ 1034.876	5.797 ／ 15.832
2B	32768	1	10761.012 ／ 2983.902	10760.952 ／ 2983.845	3.045 ／ 10.982
4B	16384	2	11256.195 ／ 2975.716	11256.164 ／ 2975.685	1.456 ／ 5.506
4B	32768	1	42070.823 ／ 8866.022	42070.765 ／ 8865.966	0.779 ／ 3.696

模型	输入	解码，词元/s	请求时长，s	峰值 RSS，MiB
2B	16384	1.659 ／ 2.914	2868.832 ／ 1057.226	2571.781 ／ 2569.617
2B	32768	1.051 ／ 2.141	10822.886 ／ 3014.282	2767.641 ／ 2766.426
4B	16384	0.490 ／ 1.117	11388.985 ／ 3033.905	5600.367 ／ 5600.611
4B	32768	0.291 ／ 0.752	42294.220 ／ 8952.505	6117.164 ／ 6117.809

模型	输入	首词元时间减少	预填充提升	解码提升
2B	16384	63.43%	+173.13%	+75.59%

模型	输入	首词元时间减少	预填充提升	解码提升
2B	32768	72.27%	+260.64%	+103.72%
4B	16384	73.56%	+278.29%	+128.23%
4B	32768	78.93%	+374.52%	+158.34%

独立检查核对了 12 次请求、221 份收据和 101704 个内存采样。控制器总耗时 28.381 h，没有请求达到冻结的时间或内存上限。RSS 采样覆盖服务器加载和请求，标称间隔 1 s。采样到的最低系统可用内存为 11396.441 MiB，最高服务器 RSS 为 6117.809 MiB。完整协议、样本范围和复现命令见容量报告。

6. 正确性与失败记录

最终构建通过 104 项 route、95 项注意力、432 项 SSM 和 158 项 GDN 原生检查。转储散列与已核验的 RC1 参考一致。两个模型共 64 条全词表状态记录逐位一致。这些记录覆盖 RS 0 ／ 3、状态清空，以及上下文 4096 下的 32 ／ 33 ／ 64 ／ 96 前缀。

6 次完整自然回答覆盖两个模型的起点、RC1 C0 和最终版三臂。每次回答都自然停止，并通过冻结 Unicode 任务的 106 项功能检查。2B 三臂全文一致，各生成 508 个词元。4B 起点生成 595 个词元，全文不同。RC1 与最终版的 4B 回答全文一致，各生成 521 个词元。两种 4B 文本都通过功能检查。

r1 交付通过数值检查，但参数解析器的 GPU 默认值断言失败。r2 修正了该断言，但启动时自动使用 4 个槽位。r3 在源码中把服务器默认槽位固定为 1，并完整重新构建。两个失败版本的源码、构建身份和日志都已保存。

旧的三项全开组合在 4B ／ 2048 ／ 65 上相对 B1 退化 3.0220477%，该结论在原测量条件下保留。IME 标量调度候选未通过性能初筛，继续排除。GPU 卸载和分页分配的内存收益没有合格结果。预测器的误差和宽区间与实测模型结果分开记录。

最终搜索测试 B1-r2、C1 和 C2-r2 的 8 种组合，都没有启用 MTP。此前的 MTP 试验在两个模型上都通过了相对质量门槛。该试验的六题总耗时，2B 减少 8.63%，4B 减少 15.22%。MTP 保持关闭，原因是该试验另设了绝对可用性门槛。直接解码在区间代码题和 2B 算术题上同样未通过该门槛。下一步计划将在 r3 上按相对质量门槛和分类速度门槛重新测试 MTP。

7. 部署与证据包

成果包目录 `final-release` 包含可运行代码、一键部署入口、官方转换脚本、部署说明、性能报告和设计说明。它包含完整生产源码与二进制、固定的转换源码、模型身份元数据和独立证据归档。生产二进制保持原核验散列。新入口先创建 tmux 会话并取得共用锁，再启动服务器。两个模型的启动都通过身份、实际默认值、锁和健康检查。

```
bash deploy.sh /absolute/path/to/model.gguf
```

成果包清单、检查表和文件散列记录了完整内容。交付计划列出六项材料的对应位置。

归档版本也可以直接启动。两个模型使用同一个二进制和同一组默认值，只更换模型路径。在 tmux 中，从解压后的版本目录执行：

```
bash package/with-lock.sh python3 package/start.py --model /path/to/model.gguf
```

依赖目录不同时，使用 `--spert` 和 `--tcm` 指定库位置。这两个参数只选择库位置，不选择性能配置。启动器核对二进制、模型和运行库散列。二进制迁移后，两个模型的启动都通过检查。

归档为 `lab/final-default-20261013/release/k1-final-20261013-r3.tar.gz`。外部旁注文件记录归档 SHA-256。Git 文本视图省略大型转储、线程采样和二进制。严格重放收据需要保留的完整归档。本地检查核对 338 份对照收据和 119 份最终验证收据。搜索检查另核对 951 份搜索收据和 19 份原生收据。

8. 历史证据

10 月 12 日快照保存旧版报告的全部内容。不同对照下的历史百分比不能相加或相乘。10 月 7 日发布和 10 月 13 日 RC1 保留为对照记录。项目工作总账列出全部工作、采用项和每个停止事项的原因。下一步计划按预期收益排列剩余实验。

适用范围

配置：MUSE-Pi-Pro，K1 ／ X60，标称 16 GB 内存，版本 `k1-final-20261013-r3`，4 线程，批大小 32，F16 键值缓存，单槽。样本：512 和 2048 输入每形状 3 对；8192 和 32768 输入每个模型 1 对；16384 输入每个模型 2 对。自然回答检查每个模型每臂使用一个 Unicode 代码任务。默认配置是冻结搜索范围内的均衡选择。整体对照没有分离各项已采用路径的贡献。

- 待验证：8192、16384 和 32768 输入的重复稳定性。阻塞：这些形状只有 1～2 对。解除条件：每形状至少测量 3 对。
- 待验证：通用质量和多轮质量。阻塞：固定多轮质量套件没有在 r3 上执行。解除条件：在两个模型上按相对质量门槛执行该套件。
- 待验证：长文语义质量和长状态正确性。阻塞：16k 和 32k 请求使用 65 个强制输出词元。解除条件：在 r3 上执行自然长文回答和长状态检查。
- 待验证：官方模型来源和完整转换。阻塞：两个官方检查点没有完整的下载与转换记录。解除条件：用随包脚本转换两个检查点，再与现用 GGUF 比较文件和回答。
- 待验证：宽 RVV、route 3、B1-r2 和 C1 各自的贡献。阻塞：最终对照只比较整体版本。解除条件：在同一 r3 二进制上逐项关闭并配对测量。
- 待验证：确切依赖的统一公开下载归档。阻塞：厂商运行库不在交付包中。解除条件：发布确切运行库文件及其 SHA-256。
- 待验证：8 GB 设备上的运行。阻塞：没有测试 8 GB 板。解除条件：在 8 GB 板上执行容量协议。